

音乐标签预测中有限艺术家数据下的概率校准

正则化与数值可复现性的回顾性和前瞻性研究

宋承麟

预印本 v1 • 2026 年 10 月 6 日 • 未经同行评审

摘要

当带标签的校准艺术家较少时，事后校准可能使概率估计变差。本文结合历史音乐标签基准与预先规定的新艺术家评价。历史基准包含 1,206 首歌曲、469 个艺术家标识、四个可重叠风格标签、三种音频表征和两种加权设置，采用 20 个相互重叠、划分内部按艺术家隔离的实验划分。七种概率处理方法使用 24、47 或 94 位校准艺术家的预算。在 18 个历史汇总条件中，恒等映射中心的岭正则化 Platt 均比普通 Platt 的平均 Brier 损失更低，但在六个未加权部分预算条件中均差于原始输出。历史数值验证在 macOS、Linux 和 Windows 上重现了选择与回退决策，最大概率差异为 1.836×10^{-13} 。随后的同来源评价保留 94 个新艺术家标识的 143 首校准歌曲，以及另 400 个新艺术家标识的 637 首评价歌曲；全部入选歌曲保留，样本通过预定覆盖检查。预定主比较在 20 个固定未加权 MAEST 分类头、五次抽样及 24/47 位艺术家预算上平均岭正则化 Platt 减去普通 Platt 的损失差。Brier 差异为 -0.007050 ，以固定分类头和校准池为条件的配对评价艺术家自助法 95% 区间为 $[-0.008361, -0.005748]$ ，支持相对普通 Platt 的平均优势。这不等于超过更简单的对照：两个部分预算下，岭正则化相对原始输出的点估计仍较差；加权部分预算中，解析修正也优于岭正则化。94 位艺术家时，两种加权设置下岭正则化相对普通 Platt 的区间均包含零。结果支持保留原始输出和解析修正，并区分统计证据与数值可复现性。结论限于单一音乐集合中的有噪声来源标签，不构成新算法或跨数据源泛化结论。

关键词：概率校准；音乐标签；有限校准数据；正则化；艺术家分组；数值可复现性

1 引言

音乐分类器可能为一首歌曲给出 0.8 的风格概率，但在获得相似分数的歌曲中，实际带有该标签的比例却低得多。概率校准关注的正是数值信心与观察结果之间的一致程度。多标签音乐识别允许一首歌同时属于 electronic 和 pop，因此本文研究的四个概率是相互独立建模的二元预测，而不是总和必须为 1 的互斥类别概率。分析校准效果时，既需要逐标签评价，也需要说明参考标签的含义。

已有方法包括 sigmoid 拟合、温度缩放、保序回归和 beta 校准[1, 2, 3, 4]。当可用于校准的艺术家较少时，拟合映射究竟是在纠正系统偏差，还是在追随校准样本的偶然特征，是一个实际问题。尤其当原始分类器的概率表现已经较好时，不作调整本身就是有意义的基线。向恒等映射收缩的正则化可以限制调整幅度，但利用同一个小校准池选择正则化强度，也会引入额外的不稳定性。

本文利用一个音乐分类项目保存的分数，研究两个相关问题：概率质量如何随校准预算和艺术家选择变化；在数据和统计目标固定时，数值求解器的终止行为是否会改变交叉验证选择。本文的贡献是保留不利结果、具备审计记录的实证比较。恒等映射正则化、概率校准映射和有界优化均有既有研究基础，本文不主张算法创新。

历史基准中的全部歌曲都已用于先前项目实验。同一历史划分内，分类器拟合、校准和评价采用不同艺术家标识，但这种划分不能消除项目先前的数据暴露。后续协议排除已记录的项目暴露后，规定了新艺术家评价。两个阶段的证据范围不同：历史基准描述已经观察的数据，前瞻性比较则在同一来源中新选取的艺术家上检验固定假设。

2 相关研究

Platt 提出了将分类器分数映射为概率的 sigmoid 方法[1]; Zadrozny 和 Elkan 研究了使用保序回归等方法进行概率转换[3]。温度缩放提供了参数较少的事后校准基线[2], beta 校准则使用更灵活的单调概率变换族[4]。本文的 Platt 实现以 logit 为输入, 包含恒等映射, 不能将“直接作用于概率的某类 logistic 映射不包含恒等映射”的结论套用到本文实现上。

正则化及内部交叉验证在概率校准中已有应用[5]。近期预印本也明确使用了向恒等变换收缩的惩罚[6]。这些方法的多类别设置与本文的二元实现并不等价, 但足以说明一般性的恒等映射收缩思路并非本文首创。数值稳定性和 sigmoid 拟合收敛问题同样已有专门研究[7]。

类别加权本身可能改变模型输出与真实事件概率的关系, 因此本文保留基于分类器拟合样本类别计数的解析修正[8]。深度音频分类器的不确定性校准也已有研究[9]。本文采用较窄的实证设置: 固定分类器, 改变校准艺术家的数量与身份, 同时记录统计变化和数值变化。

Brier 分数用于评价概率预测[10], 但它衡量的是总体概率质量, 不能单独等同于校准误差; 可靠性、分辨能力等因素均会影响其数值[11]。校准评价还依赖定义、估计方法与样本量[12]。因此, 历史分析将配对 Brier 差异作为主要描述性指标, 保留对数损失和标签层面的诊断, 不把 Brier 降低解释为所有概率区间都已可靠。

3 数据与实验设计

3.1 历史分数数据包

数据包源于 MTG-Jamendo[13], 包含 1,206 首开发歌曲与 469 个艺术家标识。由原始标签归并得到 electronic、pop、ambient 和 rock 四个宽类别, 其正标签数依次为 435、261、244 和 220, 类别可以重叠。固定的标签本体将相关标签映射到这些类别, 例如 synthpop 同时映射至 electronic 和 pop, poprock 同时映射至 pop 和 rock。它们是可能有噪声或缺漏的来源标签, 并非本研究逐首人工听辨后形成的真值。

本文比较三种已经保存的表征: Discogs-MAEST 及两个 MERT 变体[14, 15]。经审计, MAEST 特征为 2,304 维; MERT-v0 和 MERT-v1 使用已保存第 1 至第 12 层特征的均值, 得到 768 维向量。源流程使用歌曲前 30 秒的音频片段。历史分析不重新提取音频特征, 也不改变编码器权重。每个源条件都保留分类器分数, 以及拟合、校准和评价歌曲的标识。

20 个历史划分各包含 281 位拟合艺术家、94 位校准艺术家和 94 位评价艺术家, 对应的歌曲数范围分别为 710 至 736、228 至 254 和 225 至 255。源流程从 256 个按艺术家生成的候选划分中, 依据规模和标签平衡选择划分。同一划分内部的三个角色不存在艺术家标识重叠, 但不同划分相互重叠; 三种表征也使用同一批歌曲, 不能视为三个独立数据集。标准化器与 logistic 分类头仅使用拟合集训练, 分类头参数 $C = 0.001$ 。两种加权设置分别为不加权, 以及仅对 ambient 分类头使用平衡类别权重, 其余三个分类头构成完全相同的配对对照。

表 1 实验范围与统计单位。重复执行并不产生新的独立歌曲或数据集。

组成	设置
歌曲与艺术家	1,206 首歌曲；469 个艺术家标识
标签	electronic 435；pop 261；ambient 244；rock 220
源条件	20 个划分 $\times$ 3 种表征 $\times$ 2 种加权 = 120
校准预算	24 / 47 / 94 位艺术家
校准歌曲数	41–87 / 93–149 / 228–254（五次后续抽样）
后续稳定性分析	1,800 次执行；1,320 个不同源条件与子集组合
含初始抽样的数值复现	2,160 次执行；1,560 个不同组合

3.2 校准预算与艺术家交叉验证

在每个外层划分中，以固定种子打乱校准艺术家的顺序，取嵌套子集，分别包含 24、47 和 94 位艺术家，对应向上取整后的 25%、50% 和 100% 预算。选中艺术家的全部歌曲均被保留。相同划分与抽样下，各表征及加权设置使用完全相同的子集，不为获得有利的类别比例而重新抽样或平衡目标标签。初始预算种子为 2026100101，五次后续抽样种子为 2026100201 至 2026100205，后者构成主要稳定性分析。

岭正则化强度按标签独立选择，使用选定校准子集上的三折艺术家分组折外预测，内部种子为 2026100102。每位艺术家的全部歌曲只进入一个折。即使分折规则和内部种子不变，所选艺术家发生变化时，其折归属也可能改变。因此，多次抽样衡量的是整个子集选择与内部选择流程的变化，不能单独识别纯粹的样本构成效应。

每次抽样执行 $20 \times 3 \times 2 \times 3 = 360$ 个源条件与预算组合。五次后续抽样共执行 1,800 组，但由于全预算端点输入相同，仅对应 1,320 个不同的源条件与子集组合。加上单独报告的初始抽样，共有 2,160 次执行和 1,560 个不同组合。用于科学结果汇总时，每个源条件的全预算端点只计一次。

3.3 数据暴露与研究时间顺序

第一份预算实验协议于 2026 年 10 月 1 日制定，当时已经观察过更早的校准实验。稳定性扩展于 10 月 2 日、在初始预算实验结果已知之后制定。随后，在六次完整 v2 运行之前冻结了数值可移植性协议。这些是探索性研究的版本化执行计划，并非预注册或新数据确认。历史结果表格由保存的 v2 结果事后整理得到，没有重新拟合，也没有改变协议定义的比较。初始抽样结果在附录 B 单列，不作为第六次后续抽样合并。

3.4 预先规定的新艺术家样本

在历史结果已经知晓后，研究于 2026 年 10 月 3 日、取得新样本音频之前冻结了前瞻性协议。该协议在 MTG-Jamendo 内部选择未出现在已审计项目暴露记录中的艺术家。资格核查使用了来源元数据，但没有依据新分类器结果选择样本。这是一份具有内部时间记录的执行协议，不声称已公开预注册，也不声称样本从未出现在编码器预训练数据中。

符合条件的抽样框包含第 20 至 39 号音频归档中的 1,912 首歌曲、553 个艺术家标识。资格条件包括官方风格元数据、至少 30 秒的时长、音频校验和及允许的录音许可证。所有风格均可进入抽样，包括不属于四个重点标签的歌曲。固定哈希排序选出 94 位校准艺术家和 400 位评价艺术家，每位最多取两首歌。冻结名单包含 143 首校准歌曲和 637 首评价歌曲。这些是入选数量，处理损耗与最终标签

支持度另见表 4。这种不按目标标签配额抽样的方式，不同于历史上为增加标签覆盖而构建的歌曲集合。歌曲加权结果对应先抽艺术家、每位最多两首的集合，不能直接解释为从完整曲库等概率抽取歌曲的结果。

保留全部 20 个历史 MAEST 分类器种子及两种加权设置，共 40 组固定标准化器与分类头，不根据历史表现挑选分类头，也不重新训练其参数或编码器权重。新音频采用相同的前 30 秒 MAEST 特征提取流程。获取失败及检出的精确音频重复按固定规则删去歌曲或涉及的艺术家的，不补充替代样本。名义校准预算仍为 24、47 和 94 位艺术家；每次分析均记录实际保留子集，并沿用原定分析。附录 C 说明获取、校准及完整性规则。

4 校准方法与评价

4.1 七种概率处理方式

设 z 为固定二元分类器的 logit， σ 为 logistic 函数，原始概率为 $\sigma(z)$ 。所有处理方式均不在四个标签之间进行归一化。参数映射在选定校准歌曲上最小化未加权的平均二元负对数似然，其中岭正则化 Platt 额外加入所述惩罚项。参数拟合从恒等映射初始化。各方法定义见表 2。

表 2 概率处理方法。v1 与 v2 使用相同的参数边界、候选惩罚和并列选择规则。

方法	定义
Raw 原始输出	$\sigma(z)$ ，无需校准数据。
Prior offset 先验偏移	仅对加权 ambient 的 z 加 $\log(n_+/n_-)$ ，计数来自分类器拟合集。
Temperature 温度缩放	$\sigma(az)$ ， $a \in [0.001, 100]$ ，拟合平均二元 NLL。
Platt	$\sigma(az + b)$ ，有界参数，拟合 NLL，不平滑 0/1 目标。
Beta	$\sigma(a \log p - b \log(1 - p) + c)$ ，有界单调映射。
Isotonic 保序回归	非递减最小二乘映射；拟合范围外按端点截断。
Ridge Platt 岭正则化	$NLL + \lambda[(a - 1)^2 + b^2]$ ；艺术家折外 Brier 选择 λ 或恒等映射。

Platt 与岭正则化 Platt 的输出为

$$q = \sigma(az + b) \quad (1)$$

其中 a 取值于 $[0.001, 100]$ ， b 取值于 $[-20, 20]$ 。本文使用原始 0/1 目标，不采用原始 Platt 方案的目标平滑。岭正则化 Platt 最小化

$$J_\lambda(a, b) = L(a, b) + \lambda[(a - 1)^2 + b^2] \quad (2)$$

其中 L 为平均二元负对数似然。惩罚使参数向 $a = 1$ 、 $b = 0$ 收缩，而非向零斜率收缩。候选惩罚系数为 0、0.001、0.01、0.1 和 1，另加入无需拟合的精确恒等映射。每个标签使用折外 Brier 选择候选方案；与最小值相差不超过 10^{-12} 时视为并列，优先选择恒等映射，其次选择最强的有限惩罚。若选中有限惩罚，再用全部已选校准歌曲重新拟合。该规则不能保证改善评价损失。

对于使用平衡类别权重训练的 ambient 头，解析先验偏移修正在其 logit 上加 $\log(n_+/n_-)$ ，其中正负样本数只来自分类器拟合标签。未加权情况及其他三个标签均保持原始输出。该修正依据理想化的加权风险关系，不保证重现另行训练的、带正则化的未加权分类头，而且不需要校准标签。

Beta 校准使用 $\sigma(a \log p - b \log(1 - p) + c)$ ，其中 $p = \sigma(z)$ ， a 和 b 取值于 $[0.001, 100]$ ， c 取值于 $[-20, 20]$ ；对数项由 z 稳定计算。保序回归以 z 为输入拟合非递减的最小二乘映射，超出拟合输入范围时使用端点值。这些边界与截断方式属于本文的具体实现，不能据此推断所有同名方法的表现。

4.2 指标与汇总规则

两个阶段共同采用的指标为宏平均二元 Brier 分数，对四个标签等权平均，在每个评价划分内对歌曲等权平均：

$$BS = \frac{1}{4n} \sum_{j=1}^4 \sum_{i=1}^n (q_{ij} - y_{ij})^2 \quad (3)$$

历史分析的配对变化定义为 $\Delta BS = BS(\text{处理方法}) - BS(\text{原始输出})$ ，负值表示该方法更好。岭正则化 Platt 相对普通 Platt 的差异是第二个协议规定的描述性比较。后续分析先在每个外层划分内平均五次抽样差异，再对 20 个外层划分等权平均。全预算端点每个划分只保留一份。计算对数损失时，将概率截断到 $[10^{-15}, 1 - 10^{-15}]$ ，此截断仅用于评分。逐标签 Brier、平均精度以及固定 5 箱和 10 箱的可靠性汇总保留在归档结果中。

“方向反转”要求五次抽样中至少有一次改善、一次变差，绝对并列容差为 10^{-12} ；仅出现并列不算反转。极差仅描述已观察的抽样，不是置信区间。由于划分重叠、歌曲重复使用和部分标签对照完全相同，不能将所有实验执行当成独立重复。历史分析不进行划分层面的 t 检验，不构造总体置信区间，也不估计足够校准样本量的下限。

4.3 数值求解与验证

原 v1 实现使用 L-BFGS-B。少数优化不收敛会在内部折中触发已声明的恒等映射回退，使候选分数随平台变化。v2 改用带边界约束的 Newton 步、解析梯度与 Hessian、补偿求和和固定顺序的 Cholesky 求解。当曲率或线搜索阻碍推进时，使用固定顺序的坐标导数符号二分法作进一步求解。统计目标、参数边界、初始化、候选网格与选择规则均保持不变。

成功拟合要求参数有限且满足边界约束、目标函数无实质增加、盒约束投影梯度的无穷范数不超过 2×10^{-12} ，以及相对拟议参数步长不超过 2×10^{-12} ，最多迭代 300 次。校准目标只包含一个类别时，仍使用显式记录的恒等映射回退。数值不收敛也保留为失败状态，但 v2 验收要求数值失败回退为零。数据损坏和程序错误会停止运行，不能被转换成回退结果。

独立验证路径重新计算目标函数、梯度、预测概率、折外选择和最终指标。跨平台逐项比较所有评价概率以及所有候选的折外概率，包括未选中的候选，绝对容差为 10^{-8} 、相对容差为零。选中的惩罚项及全部回退决策必须完全一致。在弱识别设计中，参数本身可能不唯一；相比要求迭代次数相同，检验预测一致性与约束下的一阶收敛更有意义。

4.4 前瞻性主比较与不确定性

新评价只有一个主要比较：在未加权分类头下，岭正则化 Platt 减去普通 Platt 的损失差。对每首评价歌曲，先在四个标签、全部 20 个固定分类头、五次预定校准抽样以及名义 24 位和 47 位艺术家预算上等权平均平方损失差，再对评价歌曲等权平均。该过程平均的是损失，不是预测概率，也不构成一个预测集成模型。全预算、加权分类头及其他方法比较均属次要分析。

依据自助法原理[16]，配对艺术家簇重抽样对评价艺术家进行 10,000 次有放回重抽样。每次被抽中的艺术家贡献其全部保留歌曲，再以损失差总和除以该次抽样的歌曲总数。第 2.5 和 97.5 百分位数构成双侧 95% 区间。该区间以固定分类头、校准池和子集计划为条件，不包含另取校准总体、重新训练

分类器、样本缺失或标签错误带来的变异。同一校准池中的五次子集抽样不构成独立重复。次要比较使用相同的重抽样，区间仅作未经多重比较调整的逐项描述。

主要假设获得支持，需要预定覆盖检查通过，且区间上端点低于零。区间包含零时，结论为证据不确定。覆盖要求包括：总体及每个名义校准子集保留至少 80% 的入选艺术家；评价部分保留至少 320 位艺术家和 80% 的入选歌曲。每个标签还须至少有 20 位评价艺术家包含正标签歌曲，以及 20 位艺术家的保留歌曲全部为负标签。任一门槛未达到时，无论点估计方向如何，均报告为证据未完成。看到结果后不扩大或替换样本。

5 结果

5.1 校准预算与原始输出基线

图 1 及附录 A 报告历史基准中的全部七种方法。在 18 个表征、加权与预算组合中，岭正则化 Platt 的平均 Brier 均低于普通 Platt，但这一优势依赖比较对象。在未加权分类器中，三种表征的 24 位和 47 位艺术家预算下，岭正则化 Platt 均差于原始输出。以 MAEST 为例，原始 Brier 为 0.132160；24 位艺术家时，岭正则化 Platt 为 0.135346，普通 Platt 为 0.141133。正则化减轻了劣化，却没有消除劣化。




图 1 五次后续抽样中，相对原始输出的平均配对 **Brier** 差异。低于零表示校准更好。94 位艺术家的端点每个外层划分只计一次。连线仅连接三个已测试预算，不估计中间预算。六个面板采用相同纵轴范围，未绘制或暗示置信区间。图中 **Prior offset**、**Temperature**、**Platt**、**Beta**、**Isotonic** 与 **Ridge Platt** 依次对应表 2 的方法。

Ambient 加权条件提供了一个可被校准修正的系统偏移。MAEST 的原始 Brier 为 0.140444，随预算增加，岭正则化 Platt 依次得到 0.137985、0.134335 和 0.132595。然而，无需校准标签的先验偏移修正已经达到 0.132749。在三种表征的两个部分预算下，该解析修正的平均 Brier 均低于岭正则化 Platt。如果只比较需要拟合的校准器，就会夸大小样本下拟合映射的实际必要性。

增加灵活性并不总有帮助。未加权 MAEST、24 位艺术家条件下，beta 与保序回归的分数分别为 0.141982 和 0.148302，而原始分数为 0.132160。全预算下，部分 MERT 条件中 beta 或岭正则化略优，未加权 MAEST 则仍以原始输出更好。这些是已暴露数据上的描述性比较，不能作为查看评价结果后选择部署方法的规则。

5.2 艺术家子集带来的变化

平均差异可能掩盖对艺术家选择的敏感性。Ambient 加权 MAEST、24 位艺术家条件下，岭正则化 Platt 的平均 ΔBS 为 -0.002458，但 20 个外层划分中有 15 个在五次抽样间发生方向反转，划分内平均极差为 0.010933。47 位艺术家时，平均 ΔBS 为 -0.006109，反转减少至 2 个划分，平均极差为 0.004989。图 2 展示各划分的实际取值范围，而非合并后的不确定性带。




图 2 Ambient 加权 MAEST 中，岭正则化 Platt 相对原始输出的敏感性。每条横线表示一个历史划分在五次抽样中的最小和最大差异，圆点为均值。两幅图使用同一划分顺序。线段是观测极差，不是置信区间；24 artists 和 47 artists 分别表示 24 位与 47 位校准艺术家。

未加权 MAEST 的两个部分预算下，平均差异均为正，分别为 +0.003186 与 +0.001061；方向反转分别出现在 7 个与 13 个划分中。综合所有表征、权重、部分预算和标签，960 个设计条件中有 870 个在五次抽样间改变了所选岭正则化方案。该计数包含加权设置之间三个相同标签的重复，并非独立样本频率。它说明选择流程具有敏感性，并不代表每次惩罚系数变化都会导致较大的概率变化。

5.3 三种系统上的数值一致性

三种系统均完成六个冻结的 v2 计划，并分别通过 166 项测试。每个系统上的 159,327 次优化拟合全部收敛，数值失败回退为零；360 次单类别内部拟合按协议保留恒等映射回退。600 次重复的全预算执行在各自系统内部完全一致。macOS、Linux 和 Windows 所选惩罚项，以及回退标记、原因和次数均完全一致。

表 3 相对 CI macOS 参考结果的最大绝对概率差异。预先规定的验收容差为 10^{-8} ；计数与选择结果要求完全一致。

比较	评价概率	候选折外概率
Linux / CI macOS	1.160738×10^{-13}	1.835754×10^{-13}
Windows / CI macOS	1.160738×10^{-13}	1.835754×10^{-13}
Local macOS / CI macOS	0	0

每次平台比较覆盖 14,563,584 个评价概率、7,250,400 个候选折外概率、51,840 个候选分数与 42 份数值结果文件。最大概率差异为 1.835754×10^{-13} ，最大候选分数差异为 1.046385×10^{-14} 。这证明的是冻结输入、软件版本和受测环境下的一致性，既不是对所有硬件的逐比特确定性保证，也不是在新数据上的独立复现。

5.4 更充分的优化也可能使评价结果变差

v1 与 v2 的对照保留了三处标签级选择变化和 46 处回退位置变化。剔除重复全预算条件后，在 1,560 个源条件与子集组合中，岭正则化 Platt 的平均 Brier 增加 3.520302×10^{-6} 。单个概率的最大变化为 0.404575，说明部分变化源于实际的方案切换，而不只是浮点误差。Beta 的平均 Brier 降低 1.377194×10^{-6} ，原始输出、先验偏移修正与保序回归则保持不变。

一个诊断案例出现在 MERT-v0 的 rock 标签、24 位艺术家预算下。某个内部训练折有 42 首歌曲，其中 4 首为正标签；在可分样本上，更充分的优化使无惩罚拟合趋向原有参数边界。候选折外 Brier 由 0.093787 升至 0.143780，而恒等映射分数为 0.094201，最终选择由零惩罚变为恒等映射。两个配对加权条件中的评价宏 Brier 均增加约 0.002722，但它们共享同一个 rock 头，并非独立重复。这个案例说明，优化问题求解得更准确，与选定映射在评价数据上表现更好，是两件不同的事。

5.5 预先规定的新艺术家评价

全部 780 首入选歌曲均已获取并通过特征提取，没有艺术家或歌曲因冻结的重复规则被剔除（表 4）。校准池包含 94 个艺术家标识的 143 首歌曲；评价部分包含另外 400 个艺术家标识的 637 首歌曲。Electronic、pop、ambient 和 rock 的正标签评价艺术家分别为 157、88、68 和 99 位，全部覆盖门槛均通过。主要的岭正则化 Platt 减去普通 Platt 的平均 Brier 差异为 -0.007050，条件配对艺术家自助法 95% 区间为 $[-0.008361, -0.005748]$ （表 5）。这支持在 20 个未加权分类头、五次抽样和两个部分预算上预先规定的平均比较。

这一优势取决于比较对象。未加权原始 Brier 为 0.125033，岭正则化在 24 位和 47 位艺术家时分别为 0.128756 和 0.125368。相对原始输出的差异为 +0.003723 和 +0.000335，其中后者的逐项区间 $[-0.000009, +0.000673]$ 包含零。24 位艺术家时，岭正则化在四个标签上的 Brier 均较高，pop 的增加最大，由 0.136982 升至 0.144026。加权条件下，无需校准标签的解析偏移达到 0.124820，低于岭正则化两个部分预算的 0.131265 和 0.126142。所有需要拟合的处理方法，在未加权部分预算中的平均 Brier 均未低于原始输出，在对应加权条件中也均未低于解析偏移（表 C1）。这些是次要比较，不作为额外的确认性发现。

部分预算结果不能延伸为 94 位艺术家时岭正则化仍占优的结论。未加权条件下，岭正则化 Brier 为 0.124756，普通 Platt 为 0.124404，差异为 +0.000352，逐项区间为 $[-0.001064, +0.001758]$ 。对应加权条件下，岭正则化减去普通 Platt 的区间也包含零。表 C1 和表 C2 保留七种处理方式及两种评分规则。相对某一个拟合方法的平均 Brier 较低，不能解释为所有分数区间的概率都可靠，也不能据此在查看评价结果后选择部署方法。

新运行完成 32,508 次记录在案的优化拟合，没有数值失败或单类别回退。项目内另一路重建核查了 124,800 个分类头 logit、7,847,840 个概率及 1,760 处岭正则化折外选择。Logit 完全一致，最大概率差异为 1.665×10^{-16} ，自助法重建差异至多为 3.469×10^{-18} 。保存的时间记录显示，协议先于音频获取，预测结果则先于评价标签解析完成。此次新数值核查在 macOS 上执行，与历史三系统比较分别报告，也不等同于其他研究团队的独立复现。

表 4 新艺术家样本的入选与保留数量。名义预算对应冻结的子集计划，实际艺术家数量反映获取失败与重复排除。

阶段	校准 艺术家／歌曲	评价 艺术家／歌曲
固定选择	94 / 143	400 / 637
成功下载	94 / 143	400 / 637
去重后保留	94 / 143	400 / 637
最终可用	94 / 143	400 / 637

表 5 新样本中岭正则化 Platt 相对普通 Platt 的主要 Brier 差异及预定次要比较。区间接评价艺术家重抽样，以固定分类头和校准池为条件；次要区间未经多重比较调整，仅作逐项描述。

设置	名义预算	比较	差值与 95%区间
主要 U	24 + 47	Ridge – Platt	-0.007050 [-0.008361, -0.005748]
次要 U	24	Ridge – Platt	-0.010800 [-0.012387, -0.009192]
次要 U	24	Ridge – Raw	+0.003723 [+0.002879, +0.004572]
次要 U	47	Ridge – Platt	-0.003300 [-0.004487, -0.002134]
次要 U	47	Ridge – Raw	+0.000335 [-0.000009, +0.000673]
次要 U	94	Ridge – Platt	+0.000352 [-0.001064, +0.001758]
次要 U	94	Ridge – Raw	-0.000277 [-0.000825, +0.000268]
次要 W	24	Ridge – Platt	-0.008246 [-0.009940, -0.006524]
次要 W	24	Ridge – Raw	-0.005477 [-0.008899, -0.002016]
次要 W	47	Ridge – Platt	-0.002594 [-0.003862, -0.001347]
次要 W	47	Ridge – Raw	-0.010601 [-0.014039, -0.007184]
次要 W	94	Ridge – Platt	+0.000130 [-0.001192, +0.001450]
次要 W	94	Ridge – Raw	-0.012121 [-0.015861, -0.008323]

6 讨论与局限

两个阶段均支持保留可信的不调整选项和基于机制的修正基线。岭正则化相对普通 Platt，在全部历史汇总条件及预定新样本部分预算的平均比较中更有利，但这种优势不能说明它超过原始分数，新样本的全预算比较也没有呈现同样的方向优势。当 ambient 加权产生可预测的偏移时，只依赖拟合计数的修正可能优于从小校准样本估计映射。因此，实际选择取决于原始概率偏差的来源，以及是否存在更简单的适用对照。

重复艺术家抽样也改变了对有利均值的解释。平均差异为负时，多数外层划分内部仍可能出现方向反转。只报告均值会掩盖这一依赖。五次抽样仅提供有限的敏感性检验，不能穷尽抽样变异；而且折归属会随子集变化，现有设计无法把变化完全归因于艺术家构成，或完全归因于惩罚项选择。

历史暴露限制了回顾性证据。全部 1,206 首历史歌曲都已用于早期研究，外层划分重叠，三种表征也共享歌曲。宽类别来源标签可能存在错误或缺漏，艺术家别名未被完全识别，编码器预训练重叠也无法充分审计。音频片段与整曲标签还可能不一致。哈希检查能证明文件与保存记录一致，却不能证明标签是真值或外部数据泄漏不存在。因此，本文不能证明对任意录音或其他数据源的表现。

Brier 改善并不构成完整的校准结论。归档可靠性分箱与逐标签结果可供检查，但小样本分箱限制了其解释。历史分析不将重叠划分视作独立样本来构造总体置信区间。新评价按艺术家重抽样，其区间以固定分类头及一个校准池为条件，不能消除其他校准总体或数据来源带来的不确定性。参数边界、候选惩罚网格和实现细节也限制了结论向其他校准器的迁移。跨平台验证消除了一项计算上的歧义，却没有消除这些统计局限。

前瞻性评价补充了已观察歌曲之外的证据：全部入选艺术家均与经过审计的历史清单隔离，主要比较遵循冻结规则。历史清单包含 2,835 首歌曲和 1,296 个艺术家标识，新选择还使用了额外的署名排除。这种保护限于有记录的项目暴露及规定的精确音频检查。新样本仍来自 MTG-Jamendo，使用同一来源标签本体，五次抽样共享一个校准池。其不按标签配额抽取艺术家、每位最多两首的方式，也使抽样分布不同于历史上为增加标签覆盖而构建的集合。条件区间不能消除这些局限。使用第二来源、另行冻结协议并明确标签含义的对应关系，才能检验不同的泛化问题。

7 结论

历史基准同时记录了正则化相对普通 Platt 的益处，以及不必要的校准相对原始输出或解析对照的风险。新艺术家评价支持预先规定的部分预算平均比较：岭正则化减去普通 Platt 的 Brier 差异为 -0.007050 ，条件 95% 区间低于零。这并未说明岭正则化超过更简单的对照，全预算下与普通 Platt 的差异区间也包含零。数值验证使比较过程可供审计，但不会将同来源、有噪声标签的证据变成普遍的校准保证。本文的贡献是包含预定前瞻性检验的可复现实证研究，不是新的校准算法。

数据与代码可用性

历史代码、分数数据包、冻结协议与精简验证记录位于 <https://github.com/f0rKyrieIrving/music-probability-calibration>，对应提交 5577baf3c0048827fa5e71a940a08fd22f4a641f。该提交标识历史证据，不包含本次新确认材料。数值实现在 CI 中测试的候选提交为 816dec19044ce45d0496c4f720d33cc419309a52，随后补充的历史文档和证据未改变这些冻结的数值源代码。历史源分数包记录上游应用提交 92bc9fb8090f1c8c18c63b6dcea25ae04030b9de。完整概率签名可重新生成；托管 CI 产物有保存期限。

受测环境使用 Python 3.13.15、NumPy 2.5.2、SciPy 1.18.1 和 scikit-learn 1.9.0，协议与环境记录保存在仓库中。软件采用 MIT 许可证。源标签及其衍生分数表按 CC BY-NC-SA 4.0 提供用于非商业研究，并保留 MTG-Jamendo 署名；原音频仍适用逐录音许可证。分数包不重新分发音频、编码器权重或完整特征缓存。

仓库的 paper-v1 版本提供新确认研究的协议、分数层输入、已拟合校准记录、来源署名及汇总结果。验证脚本可在不依赖原应用或音频的条件下，重建预测及报告中的比较。公开数据包说明了它与原始本地冻结及执行记录的对应关系，不复现音频获取或特征提取；完整本地执行记录及音频不重新分发。新运行使用与历史验证相同的 NumPy、SciPy 和 scikit-learn 版本，特征提取使用 PyTorch 2.8.0。复现边界及命令见仓库 README 与 reports/fresh_confirmation_v1。

研究辅助与作者责任

项目由宋承麟发起并指导。生成式 AI 辅助了文献检索、实验设计、编程、测试、数值验证以及论文起草与翻译。论文报告的是依据保存的来源数据计算得到的结果，未添加合成观察或虚构标签。本预印本用于公开讨论，未经同行评审。宋承麟对论文的科学解释、参考文献及未来投稿声明负责。

参考文献

- [1] Platt JC. Probabilities for SV machines. In: Smola AJ, Bartlett PL, Schölkopf B, Schuurmans D, editors. *Advances in Large-Margin Classifiers*. Cambridge, MA: MIT Press; 2000. p. 61–74. doi:10.7551/mitpress/1113.003.0008.
- [2] Guo C, Pleiss G, Sun Y, Weinberger KQ. On calibration of modern neural networks. *Proceedings of Machine Learning Research*. 2017;70:1321-1330. <https://proceedings.mlr.press/v70/guo17a.html>.
- [3] Zadrozny B, Elkan C. Transforming classifier scores into accurate multiclass probability estimates. In: *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM; 2002. p. 694-699. doi:10.1145/775047.775151.
- [4] Kull M, Silva Filho T, Flach P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. *Proceedings of Machine Learning Research*. 2017;54:623-631. <https://proceedings.mlr.press/v54/kull17a.html>.
- [5] Kull M, Perello-Nieto M, Kängsepp M, Silva Filho T, Song H, Flach P. Beyond temperature scaling: Obtaining well-calibrated multi-class probabilities with Dirichlet calibration. *Advances in Neural Information Processing Systems*. 2019;32. https://proceedings.neurips.cc/paper_files/paper/2019/hash/8ca01ea920679a0fe3728441494041b9-Abstract.html.
- [6] Das S, Dasgupta N, Dutta P. Geometric calibration and neutral zones for uncertainty-aware multi-class classification. *arXiv preprint arXiv:2511.20960v1*. 2025. <https://arxiv.org/abs/2511.20960v1>.
- [7] Lin HT, Lin CJ, Weng RC. A note on Platt's probabilistic outputs for support vector machines. *Machine Learning*. 2007;68(3):267-276. doi:10.1007/s10994-007-5018-6.
- [8] Caplin A, Martin D, Marx P. Calibrating for class weights by modeling machine learning. *arXiv preprint arXiv:2205.04613v2*. 2022. doi:10.48550/arXiv.2205.04613.
- [9] Ye T, Si S, Wang J, Cheng N, Xiao J. Uncertainty calibration for deep audio classifiers. In: *Proceedings of Interspeech 2022*. 2022. p. 1556-1560. doi:10.21437/Interspeech.2022-11384.
- [10] Brier GW. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*. 1950;78(1):1-3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.
- [11] Murphy AH. A new vector partition of the probability score. *Journal of Applied Meteorology*. 1973;12(4):595-600. doi:10.1175/1520-0450(1973)012<0595:ANVPOT>2.0.CO;2.
- [12] Vaicenavicius J, Widmann D, Andersson C, Lindsten F, Roll J, Schön T. Evaluating model calibration in classification. *Proceedings of Machine Learning Research*. 2019;89:3459-3467. <https://proceedings.mlr.press/v89/vaicenavicius19a.html>.
- [13] Bogdanov D, Won M, Tovstogan P, Porter A, Serra X. The MTG-Jamendo Dataset for Automatic Music Tagging. In: *Machine Learning for Music Discovery Workshop, International Conference on Machine Learning*. 2019. <https://hdl.handle.net/10230/42015>.
- [14] Alonso-Jiménez P, Serra X, Bogdanov D. Efficient supervised training of audio transformers for music representation learning. In: *Proceedings of the 24th International Society for Music Information Retrieval Conference*. 2023. p. 824-831. doi:10.5281/zenodo.10265414.
- [15] Li Y, Yuan R, Zhang G, Ma Y, Chen X, Yin H, et al. MERT: Acoustic music understanding model with large-scale self-supervised training. In: *The Twelfth International Conference on Learning Representations*. 2024. <https://openreview.net/forum?id=w3YZ9MSIBu>.
- [16] Efron B. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*. 1979;7(1):1-26. doi:10.1214/aos/1176344552.

附录 A 全部方法比较

表 A1 和表 A2 报告全部方法的平均宏 Brier。部分预算先在每个外层划分内平均五次抽样，再对 20 个划分等权平均；全预算每个划分只计一个端点。分数越低越好，舍入仅用于展示。重复的原始输出与先验偏移值仍予保留，使比较对象清晰可见。U 表示未加权分类头，W 表示 ambient 平衡加权分类头。

表 A1 未加权分类器的五次抽样稳定性汇总，保留全部七种处理方式。

表征	艺术家	Raw	Offset	Temp.	Platt	Beta	Isotonic	Ridge
MAEST	24	0.13216	0.13216	0.13580	0.14113	0.14198	0.14830	0.13535
MAEST	47	0.13216	0.13216	0.13383	0.13608	0.13667	0.14110	0.13322
MAEST	94	0.13216	0.13216	0.13281	0.13340	0.13374	0.13712	0.13251
MERT-v0	24	0.14399	0.14399	0.14766	0.15215	0.15234	0.15847	0.14717
MERT-v0	47	0.14399	0.14399	0.14508	0.14671	0.14662	0.15110	0.14457
MERT-v0	94	0.14399	0.14399	0.14403	0.14410	0.14383	0.14708	0.14374
MERT-v1	24	0.14402	0.14402	0.14791	0.15240	0.15262	0.15994	0.14724
MERT-v1	47	0.14402	0.14402	0.14534	0.14682	0.14685	0.15182	0.14475
MERT-v1	94	0.14402	0.14402	0.14425	0.14429	0.14403	0.14696	0.14375

表 A2 Ambient 平衡加权分类器的五次抽样稳定性汇总。两种加权设置之间仅 ambient 分类头变化。

表征	艺术家	Raw	Offset	Temp.	Platt	Beta	Isotonic	Ridge
MAEST	24	0.14044	0.13275	0.14413	0.14127	0.14208	0.14855	0.13799
MAEST	47	0.14044	0.13275	0.14222	0.13621	0.13680	0.14147	0.13433
MAEST	94	0.14044	0.13275	0.14121	0.13350	0.13386	0.13735	0.13259
MERT-v0	24	0.15575	0.14422	0.15927	0.15209	0.15202	0.15834	0.14979
MERT-v0	47	0.15575	0.14422	0.15693	0.14664	0.14639	0.15079	0.14571
MERT-v0	94	0.15575	0.14422	0.15586	0.14406	0.14366	0.14697	0.14394
MERT-v1	24	0.15626	0.14420	0.16004	0.15238	0.15243	0.16003	0.14960
MERT-v1	47	0.15626	0.14420	0.15759	0.14678	0.14666	0.15177	0.14591
MERT-v1	94	0.15626	0.14420	0.15652	0.14425	0.14387	0.14709	0.14396

附录 B 初始抽样与完整实验设置

初始预算抽样是历史参考，不并入五次后续抽样估计。表 B1 保留所有表征、加权及预算下的岭正则化差异；完整的初始抽样七方法表保存在 reports/numerical_v2/budget_original。外层划分种子为 2026092800 至 2026092819，初始抽样种子为 2026100101，后续抽样种子为 2026100201 至 2026100205，内部折种子为 2026100102。

表 B1 初始抽样中岭正则化 Platt 的平均配对 Brier 变化。每项为 20 个外层划分的均值；负值表示岭正则化更好。

表征	加权	艺术家	相对 Raw	相对 Platt
MAEST	U	24	+0.003745	-0.008067
MAEST	U	47	+0.000601	-0.003623
MAEST	U	94	+0.000351	-0.000885
MAEST	W	24	-0.002395	-0.005957
MAEST	W	47	-0.006106	-0.002154
MAEST	W	94	-0.007849	-0.000908
MERT-v0	U	24	+0.003492	-0.007470
MERT-v0	U	47	+0.000316	-0.003038
MERT-v0	U	94	-0.000252	-0.000355
MERT-v0	W	24	-0.006379	-0.005419
MERT-v0	W	47	-0.009726	-0.001289
MERT-v0	W	94	-0.011809	-0.000120
MERT-v1	U	24	+0.003731	-0.007815
MERT-v1	U	47	+0.000945	-0.002960
MERT-v1	U	94	-0.000270	-0.000543
MERT-v1	W	24	-0.006151	-0.005273
MERT-v1	W	47	-0.009257	-0.000832
MERT-v1	W	94	-0.012297	-0.000293

数值复现中，Armijo 常数为 10^{-4} ，最多进行 55 次步长折半；Cholesky 主元下限为最大 Hessian 对角元素的 10^{-14} 倍；每个坐标最多进行 80 次二分。只有投影梯度残差下降时，才接受舍入误差量级的损失变化。其他算术检查与保存诊断由冻结数值协议和独立验证代码规定。这些设置均在六次完整 v2 运行前固定。

附录 C 前瞻性协议与全部方法比较

新协议在取得新音频前固定，样本量目标仅依据历史预测规划。在 20 个历史划分中，拟定主比较的艺术家簇歌曲加权比率影响量标准差，其第 90 百分位约为 0.01734。正态近似下，400 位艺术家的 95% 区间半宽约为 0.00170，320 位时约为 0.00190。将规划标准差取整为 0.02 时，400 位艺术家的半宽约为 0.00196。这些仅为规划近似，不能保证新抽样分布中的检验能力或精度。

元数据固定为 MTG-Jamendo 提交 cafd8e20c265ed84fle61flc875327971f43a62f，抽样种子为 music-calibration-fresh-confirmation-20261003-v1。允许的录音许可证包括 CC BY、BY-SA、BY-NC 和 BY-NC-SA。除已记录的历史歌曲与艺术家清单外，还保守排除三个艺术家标识，其标准化署名与历史姓名发生冲突。署名冲突属于排除预防措施，不能证明是同一个人。下载采用受大小限制的音频前缀以获取前 30 秒，不将前缀哈希称为经过验证的完整录音校验和。精确重复检查比较标准化的 30 秒、单声道 16 kHz PCM16 片段，无法排除全部重新编码、翻唱或未知预训练重叠。音频保留逐录音许可证，不重新分发。完整的前瞻性冻结 SHA-256 保存在本地 freeze.json 中，其标识前缀为 2af3f1b7222d。

校准抽样种子为 2026100301 至 2026100305，艺术家三折分配种子为 2026100311，评价自助法种子为 2026100321。缺失歌曲仅从冻结子集中删去，不重新分折或补样。94 位艺术家的计划及折归属在五次抽样中相同，仅计一次，因此共有 $20 \times 2 \times (5 \times 2 + 1) = 440$ 个不同的预定分类头、加权与子集组合。七种方法均使用既有数值 v2 实现。包括未选中内部候选在内的每次优化拟合均须收敛；来源标签仅有单类别的折保留已记录的恒等映射回退。

拟合阶段核查特征提取输出的哈希，仅使用校准目标完成拟合与选择，并在报告阶段解析评价标签前保存全部映射、候选折外记录和评价预测。这种可审计的程序隔离不等于第三方盲态保管，因为研究执行者仍可访问来源元数据。两种加权设置中未受影响的标签必须完全一致，原始输出及解析修正的预测在不同子集之间也须保持一致。数值或来源完整性失败会停止运行，不得丢弃失败记录继续分析。历史三平台验证与本次新样本的执行检查分别报告。

表 C1 和表 C2 保留每个名义预算及加权设置下的全部方法。分数平均固定分类头与子集组合的损失，全预算重复仅计一次。实际校准数量与损耗见表 4。逐标签 Brier、平均精度、可靠性分箱、拟合诊断与选择保留在对应运行记录中。未加权情况下，解析偏移与原始输出完全相同，表中仍予保留以明确比较基线。

表 C1 新样本中全部方法的平均宏 Brier 分数。三个预算表示名义艺术家数量，实际数量按冻结的损耗规则确定。U 为未加权分类头，W 为 ambient 平衡加权分类头。

加权	艺术家	Raw	Offset	Temp.	Platt	Beta	Isotonic	Ridge
U	24	0.12503	0.12503	0.12824	0.13956	0.14133	0.14932	0.12876
U	47	0.12503	0.12503	0.12628	0.12867	0.13060	0.13785	0.12537
U	94	0.12503	0.12503	0.12510	0.12440	0.12571	0.13076	0.12476
W	24	0.13674	0.12482	0.14045	0.13951	0.14119	0.14921	0.13126
W	47	0.13674	0.12482	0.13821	0.12874	0.13047	0.13794	0.12614
W	94	0.13674	0.12482	0.13686	0.12449	0.12590	0.13103	0.12462

表 C2 新样本中全部方法的平均宏对数损失，使用与表 C1 相同的实验组合。只有计算对数损失时才按固定评分边界截断概率。

加权	艺术家	Raw	Offset	Temp.	Platt	Beta	Isotonic	Ridge
U	24	0.39718	0.39718	0.41894	0.50371	0.54382	1.98488	0.42354
U	47	0.39718	0.39718	0.40360	0.41056	0.42244	1.09967	0.39840
U	94	0.39718	0.39718	0.39666	0.39504	0.39834	0.51486	0.39646
W	24	0.42715	0.39682	0.44904	0.50461	0.54842	1.97093	0.43069
W	47	0.42715	0.39682	0.43340	0.41074	0.42221	1.09387	0.40060
W	94	0.42715	0.39682	0.42676	0.39529	0.39891	0.51674	0.39627